

06. gyakorlat - Ábrázolás

Futtasd a kódokat egymás után, figyeld meg, hogyan változik az ábra az egyes paraméterek hatására, majd fogalmazd meg saját szavaiddal a szabályt. A Titanic-résznél a titanic.csv legyen az R-script mellett ugyanabban a mappában.

A tanári változat nemcsak a várható eredményt írja le, hanem azt is, milyen R-szabályt érdemes a kódból felismerni. A véletlen mintáknál konkrét szám helyett a működést és a várható mintázatot emeli ki.

Pont- és vonaldiagramok

A plot() alapesetben a kapott objektum típusától függően választ ábrázolási módot. Itt numerikus vektorokkal vizsgáljuk a tengelyeket, feliratokat és megjelenést.

```
x=c(5,7,4,8,6,4,5,4,9)
y=c(1,2,8,5,3,3,7,-1,5)
```

Magyarázat / tanulság

Két, azonos hosszúságú numerikus vektort hoz létre. A plot(x,y) ezek elemeit páronként koordinátaként tudja használni.

```
plot(x,y)
plot(y,x)
plot(x)
```

Magyarázat / tanulság

Az első az x értékeit teszi a vízszintes, y értékeit a függőleges tengelyre. A második felcseréli a tengelyek szerepét. A plot(x) egyetlen vektornál az értékeket a sorszámuk (1,2,3,...) függvényében rajzolja ki.

```
plot(x,y,main="Az első ábra") #Ábra címe
plot(x,y,sub="Az első ábra alcíme") #Alcím
plot(x,y,xlab="Az x tengely felirata") #x tengelyfelirat
plot(x,y,ylab="Az y tengely felirata") #y tengelyfelirat
```

Magyarázat / tanulság

A main a főcímet, a sub az alcímet, az xlab és ylab a tengelyfeliratokat állítja be. Az adatok nem változnak, csak az ábra feliratozása.

```
plot(x,y,xlim=c(0,10)) #x tengely skálázása
plot(x,y,ylim=c(0,10)) #y tengely skálázása
plot(x,y,ylim=c(-10,10))
plot(x,y)
plot(x,y,xlim=c(0,20),ylim=c(-10,10))
```

Magyarázat / tanulság

Az xlim és ylim a megjelenített tengelytartományt adja meg. A pontok koordinátái nem módosulnak; csak azt szabályozzuk, milyen tartomány látszódjon.

```
plot(x,y,col="red") #színezés
plot(x,y,col="magenta1")
plot(x,y,col="#a7c6d8") #RGB színkód
plot(x,y,col="#0f770c")
```

Magyarázat / tanulság

A col az ábra elemeinek színét állítja. Megadható R által ismert színnévvel vagy hexadecimális színkóddal.

```
plot(x,y,bty="o") #szegélyezés
plot(x,y,bty="L")
plot(x,y,bty="n")
```

Magyarázat / tanulság

A bty a rajzterület keretének típusát szabályozza: "o" teljes keret, "L" bal és alsó szegély, "n" pedig keret nélkül.

```
plot(x,y,pch=0) #pont ábrája
plot(x,y,pch=1)
plot(x,y,pch=19)
plot(x,y,pch=20)
plot(x,y,pch=3)
```

Magyarázat / tanulság

A pch a pontok szimbólumát választja ki. A számok különböző üres, telt vagy vonalas jelölőket jelentenek.

```
plot(x,y,type="p") #grafikon típusa
plot(x,y,type="l")
plot(x,y,type="o",pch=20)
plot(x,y,type="b",pch=20)
```

Magyarázat / tanulság

A type szabja meg a megjelenés típusát: "p" pontok, "l" vonal, "o" pontok és vonal egymásra rajzolva, "b" pontok és vonalak úgy, hogy a vonal a pontok körül megszakad.

```
plot(x,y,main="Az ábra címe",xlab="x tengely",ylab="y tengely",xlim=c(0,10),pch=20,type="o",bty="L",col="magenta1")
```

Magyarázat / tanulság

Egyetlen plot() hívásban több grafikai paraméter együtt is megadható. A kód egyszerre állít címet, tengelyfeliratot, x-tartományt, ponttípust, ábratípust, keretet és színt.

```
kocka=factor(sample(1:6,5000,replace=T))
plot(kocka)
plot(kocka,ylim=c(0,1000))
```

Magyarázat / tanulság

5000 kockadobást szimulál, majd faktorrá alakítja az eredményeket. Faktor plotolásakor az R gyakorisági oszlopdiagramot készít. Az ylim csak a függőleges tengely megjelenített tartományát módosítja.

Függvényábrázolás

A curve() egy matematikai kifejezést rajzol ki adott tartományon. Az n azt szabja meg, hány pontban számolja ki a függvény értékét.

```
curve(x^2-4*x+8, from=-5, to=7)
curve(x^2-4*x+8, from=-5, to=7, n=4)
curve(x^2-4*x+8, from=-5, to=7, n=8)
curve(x^2-4*x+8, from=-5, to=7, n=50)
curve(x^2-4*x+8, from=-5, to=7, n=1000)
```

Magyarázat / tanulság

Ugyanazt a másodfokú függvényt rajzolja -5 és 7 között. Kis n esetén kevés mintapontból összekötött, szögletesebb közelítést látunk; nagy n esetén a görbe egyre simábbnak tűnik.

```
curve(sin(x)/x, from=-10, to=10)
curve(sin(x)/x, from=-30, to=30, ylim=c(-0.5, 1.2))
```

Magyarázat / tanulság

A $\sin(x)/x$ függvényt rajzolja két különböző x-tartományon. Az ylim a látható y-tartományt korlátozza. $x=0$ -nál a kifejezés $0/0$ miatt NaN, bár matematikailag a határérték 1.

Hisztogram

A hisztogram folytonos vagy numerikus adatok eloszlását intervallumokba rendezve mutatja. A töréspontok és az intervallumok szélessége erősen befolyásolja a képet.

A forrásban szereplő példa intervallumai: (0,3], (3,5], (5,7], (7,9], a hozzájuk tartozó darabszámokkal. Figyeld meg, hogyan kapcsolódik ehhez a breaks és a right paraméter.

```
h=c(1,6,5,8,5,6,4,3,4,7,6,5,9)
hist(h)
```

Magyarázat / tanulság

Létrehozza a h vektort, majd alapbeállításokkal hisztogramot rajzol róla. Az R automatikusan választ osztályközöket.

```
hist(h,freq=T) # Gyakoriság vagy relatív gyakoriság
hist(h,freq=F)
```

Magyarázat / tanulság

freq=TRUE esetén a függőleges tengelyen darabszámok szerepelnek. freq=FALSE esetén sűrűséget rajzol úgy, hogy az oszlopok összterülete 1 legyen; ez technikailag nem egyszerűen a relatív gyakoriság, főleg eltérő osztályköz-szélességeknél.

```
hist(h,right=T) #Intervallumok zártsága
hist(h,right=F)
```

Magyarázat / tanulság

A right azt szabályozza, hogy az intervallumok jobb oldalon zártak-e. TRUE esetén tipikusan (a,b], FALSE esetén [a,b) jellegű osztályközök adódnak.

```
hist(h,breaks=c(0,3,5,7,10),freq=T) #Intervallumok beállítása
hist(h,breaks=seq(from=0.5,to=9.5,by=1.5))
```

Magyarázat / tanulság

A breaks kézzel adja meg az osztályközök határait. Lehet konkrét töréspontvektor vagy seq()-vel előállított sorozat.

```
hist(h,labels=T) #Oszlopcimkék
hist(h,labels=T,freq=F,ylim=c(0,0.5))
hist(h,col=c("red","blue","green","yellow","magenta"))
```

Magyarázat / tanulság

labels=TRUE kiírja az oszlopok értékeit. Az ylim a tengelytartományt állítja. A col több színt is kaphat; az R ezeket sorrendben használja, szükség esetén újrahasznosítja.

```
x=rnorm(5000,0,1)
hist(x)
hist(x,breaks=seq(from=-4,to=4,by=0.2))
hist(x,breaks=seq(from=-4,to=4,by=0.1))
hist(x,breaks=seq(from=-4,to=4,by=0.05))
hist(x,breaks=seq(from=-4,to=4,by=0.01))
```

Magyarázat / tanulság

5000 standard normális eloszlású véletlen számot generál. Ahogy a breaks lépésköze csökken, egyre több és keskenyebb oszlop lesz; túl sok osztályköz esetén az ábra zajosabbá válhat.

```
hist(x,breaks=seq(from=-4,to=4,by=0.1),col=heat.colors(160))
hist(x,breaks=seq(from=-4,to=4,by=0.1),col=rainbow(100))
hist(x,breaks=seq(from=-4,to=4,by=0.05),col=rainbow(200))
```

Magyarázat / tanulság

A heat.colors() és rainbow() színvektorokat készít. A hist() az oszlopok színezésére használja ezeket; ha a színek és oszlopok száma eltér, a színvektor újrahasznosodhat.

Boxplot és Titanic-adatok

A boxplot a mediánt, kvartiliseket, szóródást és kiugró értékeket szemlélteti. A Titanic-fájlt itt helyi fájlból olvassuk be, ahogy a vizsgán is.

```
titanic=data.frame(read.table("titanic.csv",header=T,sep=""))  
titanic
```

Magyarázat / tanulság

Beolvassa a helyi titanic.csv fájlt, ahol az első sor fejléc (header=TRUE), az elválasztó karakter kettőspont. A titanic kiírja az adattáblát. Ez a sor a korábbi internetes cím helyett a helyi fájlt használja.

```
boxplot(titanic$Age)  
boxplot(titanic$Age,col="red")
```

Magyarázat / tanulság

Az Age oszlop életkor-eloszlását mutatja dobozdiagramon. A col csak a megjelenés színét módosítja. A boxplot a hiányzó NA értékeket figyelmen kívül hagyja.

```
boxplot(Age~PClass,data=titanic)  
boxplot(Age~Sex,data=titanic)  
boxplot(Age~Sex:PClass,data=titanic)
```

Magyarázat / tanulság

A formula alakban a bal oldal a vizsgált numerikus változó (Age), a jobb oldal pedig a csoportosító változó. A Sex:PClass a két kategória kombinációi szerint hoz létre csoportokat.

```
boxplot(Age~PClass,data=titanic,col=c("red","seagreen1","gold"))
```

Magyarázat / tanulság

Az életkort utasosztály szerint hasonlítja össze, és a három osztály dobozait külön színekkel rajzolja.

Kördiagram

A pie() a megadott pozitív értékek arányát körszeletekként jeleníti meg.

```
pie(c(1,1,1,1,1))  
pie(c(1,1,2,1,1))  
pie(c(1,2,3,4,5,6))
```

Magyarázat / tanulság

Az első öt egyenlő szeletet ad. A másodikban a 2 értékhez tartozó szelet kétszer akkora, mint az 1-ekhez tartozók. A harmadiknál a szeletek nagysága az 1:6 arányt követi.

```
pie(1:4,radius=1) #kördiagram sugara  
pie(1:4,radius=0.5)  
pie(1:4,clockwise = T) #körüljárási irány
```

Magyarázat / tanulság

A radius a kör méretét, a clockwise=TRUE pedig a szeletek óramutató járásával megegyező elrendezési irányát szabályozza.

Oszlopdiaagram

A barplot() kategóriákhoz vagy pozíciókhoz tartozó értékeket oszlopokkal ábrázol.

```
barplot(c(7,5,3,9,6,3,4))  
barplot(c(7,5,3,9,6,3,4),ylim=c(0,12))  
barplot(c(7,5,3,9,6,3,4),horiz = T)  
barplot(c(7,5,3,9,6,3,4),horiz = F)
```

Magyarázat / tanulság

Az első alap oszlopdiaagramot készít. Az ylim a függőleges skálát rögzíti. horiz=TRUE vízszintes, FALSE függőleges oszlopokat rajzol.